

# Rozwiązywanie problemu Kuromasu za pomocą algorytmów genetycznych i rojów cząstek.

Igor Pustovoy

Kwiecień 2022

# 1 Wprowadzenie

Kuromasu, czyli "Gdzie są czarne pola" to japońska gra wydana przez Nikoli, po raz pierwszy ujrzała światło dzienne w 1991 roku.

## 1.1 Zasady

Gracz rozpoczyna grę widząc prostokątną planszę, na której w niektórych miejscach umieszczone są liczby. Przykład takiej planszy widnieje poniżej.


		9					8		
							7		
				12					16
9									
	10								
		12		8		11		3	
								3	
									3
7						2			
		7							
		2					5		

Następnie, jego zadaniem jest zamalowanie na czarno wybranych pól, tak aby każdemu polu z liczbą odpowiadała ilość białych pól w poziomie oraz pionie od tego pola, równa tej liczbie. Jeżeli jednak w trakcie liczenia napotkamy na koniec planszy albo na czarne pole, to nie możemy liczyć dalej.

Wyodrębniamy jeszcze 3 podstawowe zasady:

- Pola z liczbami muszą być białe.
- Czarne pola nie mogą się bezpośrednio dotykać.
- Każde białe pole musi łączyć się z przynajmniej jednym innym. Pionowo, poziomo lub na skos.

Rozwiązana zagadka znajduje się poniżej



## 2 Funkcje Fitness

Chromosomem będzie tablica długości sumy pól na planszy, składająca się jedynie z zer i jedynek.

0 = białe pole, 1 = czarne pole

Chromosom na czas działania funkcji przekształcimy w tablicę dwuwymiarową korzystając z biblioteki numpy.

```
# Reshaping a 1D chromosome array into a 2D one.  
solution2d = np.reshape(solution, (len(grid), len(grid[0])))
```

### 2.1 Podstawowa Funkcja Fitness

Funkcja fitness będzie zwracała ujemną ilość pól z liczbami, które mają poprawną wartość liczbową. Idealny wynik to więc 0. Jeżeli inne zasady będą złamane to w tej wersji funkcji zwracamy ujemną długość chromosomu, czyli ilość pól na planszy.

#### 2.1.1 Implementacja

Zaczynamy od sprawdzenia czy żadne z czarnych pól nie leży bezpośrednio przy innym. W tej wersji funkcji Fitness każdemu chromosomowi łamiącemu tę zasadę dajemy najniższy możliwy wynik.

```
for i in range(0, len(solution2d)):  
    for j in range(0, len(solution2d[0])):  
        if solution2d[i][j] == 1:  
            correct_placement = check_black_square_surroundings(i, j)  
            if not correct_placement:  
                return -len(solution)
```

```
def check_black_square_surroundings(x, y):
    if x > 0 and solution2d[x - 1][y] == 1:
        return False
    if x < grid_height - 1 and solution2d[x + 1][y] == 1:
        return False
    if y > 0 and solution2d[x][y - 1] == 1:
        return False
    if y < grid_width - 1 and solution2d[x][y + 1] == 1:
        return False
    return True
```

Jeżeli wiemy już, że czarne pola nie przylegają ze sobą, to nie musimy sprawdzać czy każde białe pole ma przynajmniej jedno inne białe pole w swoim otoczeniu, ponieważ jest to równoznaczne.

Następnie możemy przejść do analizy, czy wartości numerycznych pól odpowiadają białym polom pionowo i poziomo od nich. Sprawdzamy również czy żadne pole z liczbą nie jest zamalowane na czarno. Jeżeli jest, to zwracamy najniższy możliwy wynik.

```
# Check if numbered squares have correct values
numbers_wrong = 0

for i in range(0, len(grid)):
    for j in range(0, len(grid[0])):
        if grid[i][j] != 0:
            if solution2d[i][j] == 1:
                return -len(solution) # if not white
            if not check_number(i, j):
                numbers_wrong += 1
```

```

def check_number(x, y):

    def check_left(x1, y1):
        white_fields = 0
        y1 -= 1 # We don't want to count the starting square
                                     multiple times
        while 0 <= y1 < grid_width and solution2d[x1][y1] == 0:
            white_fields += 1
            y1 -= 1
        return white_fields

    def check_right(x1, y1):
        white_fields = 0
        y1 += 1
        while 0 <= y1 < grid_width and solution2d[x1][y1] == 0:
            white_fields += 1
            y1 += 1
        return white_fields

    def check_up(x1, y1):
        white_fields = 0
        x1 -= 1
        while 0 <= x1 < grid_height and solution2d[x1][y1] == 0:
            white_fields += 1
            x1 -= 1
        return white_fields

    def check_down(x1, y1):
        white_fields = 0
        x1 += 1
        while 0 <= x1 < grid_height and solution2d[x1][y1] == 0:
            white_fields += 1
            x1 += 1
        return white_fields

```

Dla każdego pola z wartością liczbową wywołujemy funkcję `check_number()`. W zależności od wyniku inkrementujemy lub nie zmienną `numbers_wrong`.

Na końcu funkcji `Fitness` zwracamy ujemną wartość zmiennej `numbers_wrong`.

## 2.2 Funkcja Fitness z punktami karnymi

W tej wersji funkcji Fitness nie będziemy od razu odrzucać chromosomów, które łamią jakąś zasadę (wyjątkiem jest przypadek kiedy pole z liczbą jest czarne), ale będziemy przyznawać ujemne punkty odpowiadające stopniowi złamania danej zasady. Metoda karania została zapożyczona z pracy magisterskiej "Comparing Methods for Solving Kuromasu Puzzles" Tima Von Meurs.

### 2.2.1 Implementacja

Za każde jedno pole różnicy między wartością liczbową, a ilością pól w zasięgu widzenia będzie naliczany jeden punkt karny.

```
directions = [check_left, check_right, check_up, check_down]
for direction in directions:
    white_fields_sum += direction(x, y)

return abs(number - white_fields_sum)
```

Wszystkie kary będą ze sobą sumowane

```
# Check if numbered squares have correct values
numbers_penalty = 0

for i in range(0, len(grid)):
    for j in range(0, len(grid[0])):
        if grid[i][j] != 0:
            if solution2d[i][j] == 1:
                return -len(solution) # Numbered squares must be white
            numbers_penalty += check_number(i, j)
```

Każde czarne pole będzie mogło dostać do 4 punktów karnych w zależności od ilości czarnych pól, które do niego przylegają.

```
def check_black_square_surroundings(x, y):
    penalty = 0
    if x > 0 and solution2d[x - 1][y] == 1:
        penalty += 1
    if x < grid_height - 1 and solution2d[x + 1][y] == 1:
        penalty += 1
    if y > 0 and solution2d[x][y - 1] == 1:
        penalty += 1
    if y < grid_width - 1 and solution2d[x][y + 1] == 1:
        penalty += 1
    return penalty
```

Wszystkie kary będą ze sobą sumowane

```
# Check for wrongly placed black squares
black_squares_penalty = 0

for i in range(0, len(solution2d)):
    for j in range(0, len(solution2d[0])):
        if solution2d[i][j] == 1:
            black_squares_penalty += check_black_square_surroundings(i, j)
```

Na końcu funkcji zwracana będzie ujemna łączna suma kar

```
return -(numbers_penalty + black_squares_penalty)
```



### 3 Algorytm genetyczny

Po przetestowaniu różnych ustawień algorytmu zdecydowałem się na poniższe:

```
sol_per_pop = 600
num_genes = len(grid) * len(grid[0])

num_parents_mating = 300
num_generations = 800
keep_parents = 15

parent_selection_type = "sss"

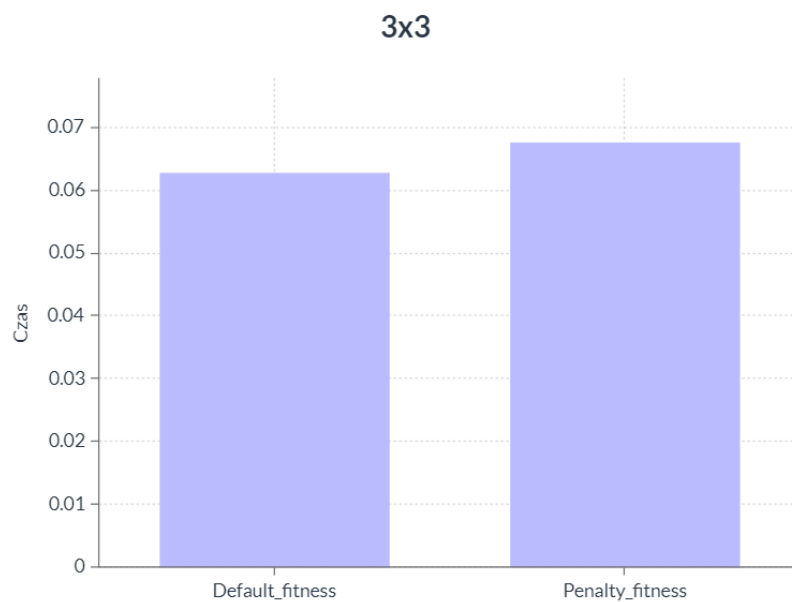
crossover_type = "single_point"

mutation_type = "random"
mutation_percent_genes = 130 / (len(grid) * len(grid[0]))
```

Na różnej wielkości planszach będziemy testować obie wersje funkcji Fitness. Dla każdej wyliczona zostanie średnia arytmetyczna ze stu powtórzeń algorytmu.



### 3.1 Plansza 3x3

	3	
3		




Na wykresie widzimy, że podstawowa funkcja Fitness średnio wykonała algorytm odrobinę szybciej niż jej wersja z karami. Dla podstawowej wersji średni czas wyniósł: 0.06286500692367554 sekund, natomiast dla rozszerzonej: 0.06770203828811645 sekund.

### 3.2 Plansza 5x5



Tym razem funkcja z punktami karnymi poradziła sobie o wiele lepiej. Dla podstawowej wersji średni czas wyniósł: 3.5706164240837097 sekund, natomiast dla rozszerzonej: 0.8856637454032898 sekund.

### 3.3 Plansza 7x7



Przy tak dużych rozmiarach planszy i ilościach liczb, standardowa funkcja fitness nie znalazła rozwiązania ani razu, ponieważ prawie zawsze musiała zwrócić najniższy możliwy wynik, przez złamanie jednej z zasad. Funkcja z karami znajdowała rozwiązanie ze skutecznością około 40%. Średni czas z udanych prób wynosił 23.11241764068603 sekundy.

### 3.4 Wniosek

Jedyny przypadek, kiedy zastosowanie standardowej funkcji Fitness jest dobrym rozwiązaniem, to przy bardzo małych planszach. W reszcie przypadków, to funkcja z karami przynosi o wiele lepsze efekty, a nawet udaje jej się rozwiązać plansze, której zwykła funkcja nie jest w stanie.

## 4 Rój cząstek

Ponieważ funkcje Fitness przyjmują chromosomy składające się wyłącznie z 0 i 1, w roju skorzystamy z binary PSO.

Po przetestowaniu różnych ustawień algorytmu zdecydowałem się na poniższe:

```
options = {'c1': 0.5, 'c2': 0.3, 'w': 0.9, 'k': 2, 'p': 1}

optimizer = ps.discrete.BinaryPSO(n_particles=500,
dimensions=grid_height * grid_width, options=options)

optimizer.optimize(f, iters=1000, verbose=True)
```

Dla funkcji f, która wygląda następująco.


```
def f(x):
    """
    x: numpy.ndarray of shape (n_particles, dimensions)

    """
    n_particles = x.shape[0]
    j = [fitness_func(x[i]) for i in range(n_particles)]
    return np.array(j)
```

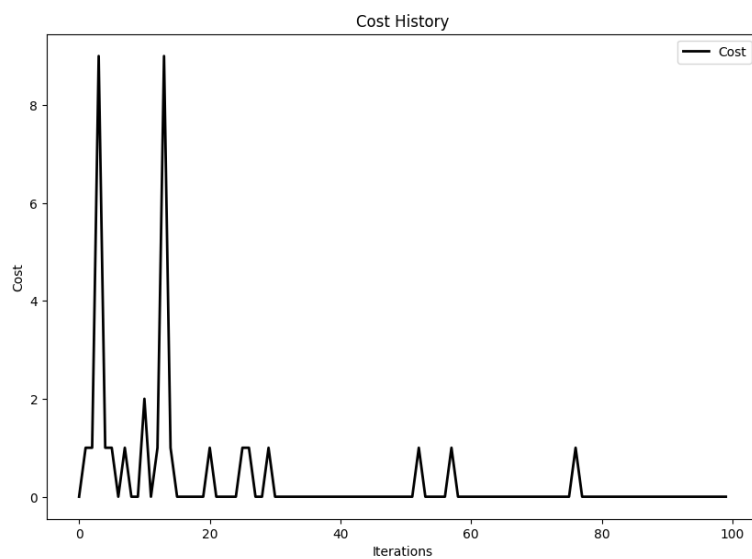
### 4.1 Funkcja Fitness

Ponieważ Rój wyszukuje minima, funkcje Fitness nie będą już zwracać ujemnych wartości.

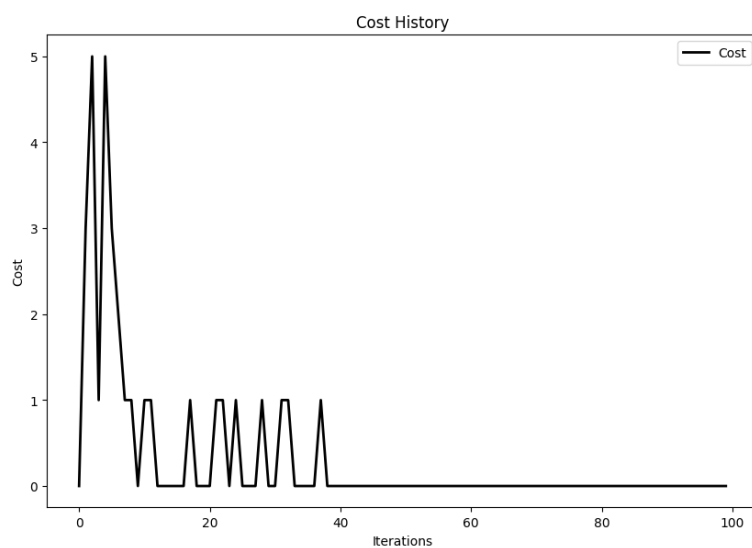
## 4.2 Plansza 3x3




Standardowa funkcja Fitness trwała 0.4269 sekundy i nie miała problemów ze znalezieniem rozwiązania.




Funkcja z karami trwała 0.5400 sekundy i również poradziła sobie bezproblemowo.



### 4.3 Plansza 5x5

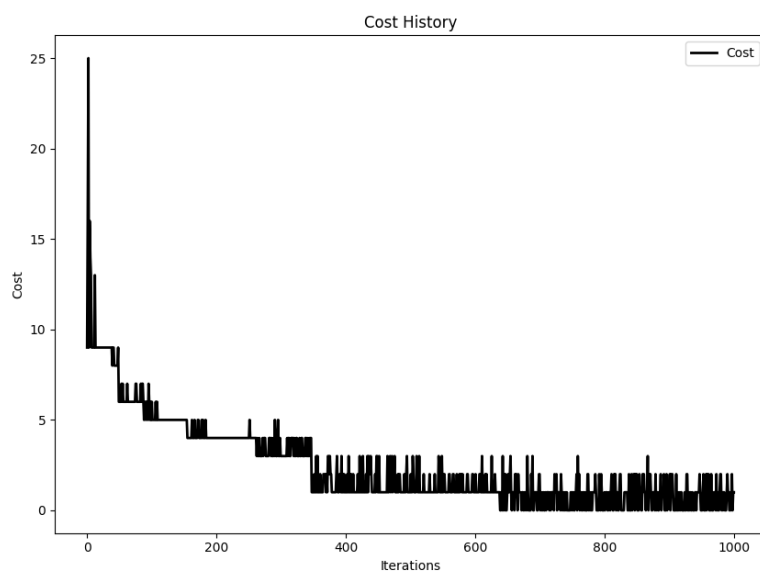


Standardowa funkcja Fitness trwała 5.7889 sekund i była w stanie jedynie zbliżyć się do rozwiązania.







Funkcja z karami niełatwo, ale znalazła rozwiązanie. Funkcja trwała 8.2725 sekund.




#### 4.4 Plansza 7x7



Standardowa funkcja Fitness trwała 157.6951 sekund i nie była w stanie zwrócić jakiegokolwiek innej wartości niż najniższa możliwa.



Funkcja z karami zajęła 165.7288 sekund i nie dała rady znaleźć rozwiązania, ale była blisko.



## 4.5 Wnioski

W przypadku roju cząstek, funkcja Fitness z karami znowu wypadła lepiej, jednakże nawet dla niej plansza 7x7 stanowi duże wyzwanie, którego nie udaje się pokonać nawet w 10000 iteracjach.

## 5 Podsumowanie

Zarówno algorytm genetyczny jak i rój cząstek są w stanie znaleźć rozwiązania dla plansz 3x3 oraz 5x5. W przypadku planszy 7x7 algorytm genetyczny sprawdza się lepiej, ponieważ może nie zawsze, ale jednak znajduje rozwiązanie.

W przypadku obu algorytmów, jedynym przypadkiem kiedy warto rozważyć skorzystanie ze standardowej funkcji Fitness, jest plansza 3x3. Kiedy mamy do czynienia z większą planszą to wersja funkcji z karami będzie dawała lepsze rezultaty.

Kuromasu jest złożonym obliczeniowo problemem. Dla naszej planszy 7x7, szansa że wszystkie pola z liczbami będą białe to  $\frac{1}{2^9}$ , a to nie jedyna zasada, która musi zostać spełniona. Nic więc dziwnego że algorytmy mają problem ze znalezieniem rozwiązania dla większych plansz.

## 6 Źródła

- [https://en.wikipedia.org/wiki/KuromasuSolution\\_methods](https://en.wikipedia.org/wiki/KuromasuSolution_methods)
- <https://theses.liacs.nl/pdf/20-TimvanMeurs.pdf>